

การจำแนกข้อความภาษาไทยเพื่อคัดกรองภาวะซึมเศร้า

Thai Text Classification for Depression Detection: Architecture, Hyperparameter Tuning & Comparative Analysis

กลุ่มผู้จัดทำ: กลุ่มที่ 10 (Group วิชา: การประมวลผลภาษาธรรมชาติ (Natural Language Processing))

ชุดข้อมูล: Depression_Dataset.csv (32,676 ข้อความ)

BEST ACCURACY

78.40%

BiLSTM + Word2Vec

HIGHEST RECALL

85.85%

คัดกรองเคสซึมเศร้าได้สูงสุด

BEST PRECISION

78.31%

LR + TF-IDF (C = 3.0)

TOTAL DATASET

32,676

Balanced Classes (~50/50)

1. บทนำและภาพรวมชุดข้อมูล (Problem Formulation & Dataset Overview)

Data Preparation

ที่มาและความสำคัญ: ภาวะซึมเศร้า (Depression) เป็นปัญหาสุขภาพจิตที่ส่งผลกระทบต่อประชากรจำนวนมาก การตรวจจับสัญญาณความเสี่ยงผ่านข้อความบนสื่อสังคมออนไลน์เป็นงานวิจัยสำคัญในกลุ่ม *Natural Language Processing (NLP)* โดยโครงการนี้มุ่งเน้นการพัฒนาแบบ **Binary Text Classification** เพื่อจำแนกข้อความภาษาไทยระหว่าง **Class 0 (ข้อความปกติ / Non-Depression)** และ **Class 1 (ข้อความบ่งชี้ภาวะซึมเศร้า / Depression)**

กระบวนการทำความสะอาดข้อมูล (Text Cleaning Pipeline):

- ลบ URL / Web Links:** ตัด Regular Expression `https?://\S+|www\.\S+` ออกเพื่อตัดสัญญาณรบกวน
- จัดการช่องว่างส่วนเกิน:** รวม White-space และตัดช่องว่างหัวท้ายด้วย `strip()`
- ตรวจสอบ Duplicate & Empty Text:** ตรวจสอบแถวที่ซ้ำซ้อนและไม่มีข้อความว่างเปล่า (Empty Text = 0)
- การแบ่งข้อมูล (Split Strategy):** แบ่งแบบ 70% Train, 15% Validation, 15% Test


ตารางแจกแจงชุดข้อมูล (Data Split Distribution):

ชุดข้อมูล (Set)	จำนวนแถว	ปกติ (0)	ซึมเศร้า (1)	สัดส่วน
Train Set	22,873	11,297 (49.4%)	11,576 (50.6%)	70.0%
Validation Set	4,901	2,420 (49.4%)	2,481 (50.6%)	15.0%
Test Set	4,902	2,421 (49.4%)	2,481 (50.6%)	15.0%
รวมทั้งหมด (Total)	32,676	16,138 (49.39%)	16,538 (50.61%)	100.0%

2.1 เทคนิคที่ 1: Deep Learning — BiLSTM + Word2Vec Embedding (Sequential Architecture)

โมเดล Deep Learning ลำดับเวลา (Sequential Architecture) ที่ผสมการตัดคำภาษาไทยด้วย **PyThaiNLP (engine: newmm)** ร่วมกับการเทรน **Word2Vec (Skip-gram, sg=1)** บนคลังคำศัพท์ของชุดข้อมูล เพื่อแปลงคำเป็น Dense Vector ขนาด 100 มิติ โดยสามารถเรียนรู้ความสัมพันธ์ของบริบทคำทั้งทิศทางหน้าและหลัง (Bidirectional Context)

BiLSTM Neural Network Architecture Pipeline (Group 10)



รูปที่ 1: แผนผังสถาปัตยกรรมโครงข่ายประสาทเทียม Bidirectional LSTM (BiLSTM Pipeline)


1. Tokenization & Mapping ตัดคำด้วย PyThaiNLP, คำนวณความยาวข้อความ (Mean=16.59 คำ, 99th%=89 คำ) กำหนด MAX_LEN = 100 และสร้าง Mapping Dict (Vocab: 9,200 คำ + PAD (0) + UNK (1) = 9,202 โทเค็น)

2. Embedding Matrix สร้าง Weight Matrix ขนาด (9202, 100) จาก Pre-trained Word2Vec, กำหนด mask_zero=True เพื่อข้าม Padding และเปิด trainable=True เพื่อ Fine-tuning

3. Bidirectional LSTM ใช้ LSTM 64 หน่วย ทั้งทิศทาง Forward และ Backward ได้ Hidden Representation ขนาด 128 มิติ เพื่อจับความสัมพันธ์ระยะยาวของประโยค

4. Regularization & Dense เริ่มต้นด้วย Dropout(0.30) → Dense(32, activation='relu') → Dropout(0.20) → Dense(1, activation='sigmoid')

5. Training Hyperparameters Optimizer: Adam (lr=0.001), Loss: Binary Crossentropy, Batch Size: 64, Callbacks: EarlyStopping(patience=3) และ ReduceLROnPlateau(factor=0.5, patience=2)



รูปที่ 2: กราฟแสดงผลการเรียนรู้ (Loss & Accuracy Learning Curves) ตลอด 5 Epochs ของโมเดล BiLSTM

2.2 เทคนิคที่ 2 & 3: Linear Models — Logistic Regression (BoW vs TF-IDF)

การสกัดฟีเจอร์ระดับคำ (N-gram Features) ผสานกับการจำแนกด้วย Linear Classifier ผ่านฟังก์ชัน Sigmoid และ L2 Regularization โดยทำการเปรียบเทียบระหว่างสองวิธีสกัดฟีเจอร์:

เทคนิคที่ 2: Bag of Words (BoW)

- **Feature Extractor:** CountVectorizer
- **N-gram Range:** Unigram + Bigram (1, 2)
- **Min Document Frequency:** min_df = 2
- **จำนวน Features:** 55,860 มิติ
- **Tuning Hyperparameter:** ค้นหา $C \in [0.001, ..., 10.0]$ พบว่าค่าที่ดีที่สุดคือ $C = 0.3$ (Validation Accuracy: 77.70%)

เทคนิคที่ 3: TF-IDF Representation

- **Feature Extractor:** TfidfVectorizer
- **Scaling:** sublinear_tf = True ($1 + \log(\text{tf})$)
- **N-gram Range:** Unigram + Bigram (1, 2)
- **จำนวน Features:** 55,860 มิติ
- **Tuning Hyperparameter:** ค้นหา $C \in [0.001, ..., 10.0]$ พบว่าค่าที่ดีที่สุดคือ $C = 3.0$ (Validation Accuracy: 78.13%)

การวิเคราะห์ค่าสัมประสิทธิ์ที่สำคัญจากค่าน้ำหนักสัมประสิทธิ์โมเดล (Top Informative Coefficients):


- **ข้อความบ่งชี้ภาวะซึมเศร้า (Class 1):** ยา, หมอ, เรา, ดริม, คุณหมอ, โรค, อาการ, ซึมเศร้า, ป่วย, ฆ่าตัวตาย, การรักษา, ทำร้าย, จิตแพทย์
- **ข้อความปกติ (Class 0):** เธอ, ความรัก, เดบิต, พี่, เขา, กบ, ดอกไม้, แสง, รัก, ยาย, ครู, เมียง

2.3 เทคนิคที่ 4: Tree-based Model — Decision Tree + TF-IDF


โมเดลจำแนกแบบต้นไม้การตัดสินใจ (Non-linear Rule-based Model) บนเวกเตอร์ TF-IDF (47,578 ฟีเจอร์) มีจุดเด่นด้านความสามารถในการอธิบายผลลัพธ์ (Explainability / Interpretability) ผ่านค่า Gini Impurity และ Feature Importance

การปรับจูนความลึก (Hyperparameter Tuning):

- **Parameter Grid:** max_depth $\in [5, 10, 15, 20, 25, 30, 50, \text{None}]$
- **Best max_depth:** 25 (Validation Acc = 67.66%, โป 899 โป)
- **การป้องกัน Overfitting:** หากไม่จำกัดความลึก (None) ต้นไม้จะจำเพาะกับ Train Set ทำให้ Validation Acc ตกลงเหลือ 66.09%



รูปที่ 3: Feature Importance 15 อันดับแรกของ Decision Tree




รูปที่ 4: กราฟแสดงผลการปรับจูน Hyperparameter: (ซ้าย) ค่า C ของ Logistic Regression, (ขวา) ค่า max_depth ของ Decision Tree

ตารางสรุปผลการประเมินประสิทธิภาพทุกโมเดลบนชุดทดสอบ (Master Comparison Table):


ชื่อโมเดล / สถาปัตยกรรม	Accuracy	Precision	Recall	F1-Score	ROC-AUC
1. BiLSTM + Word2Vec	0.7840 (78.40%)	0.7505	0.8585 (85.85%)	0.8009 (80.09%)	0.8715 (87.15%)
2. Logistic Regression + BoW	0.7783 (77.83%)	0.7574	0.8267 (82.67%)	0.7905 (79.05%)	0.8660 (86.60%)
3. Logistic Regression + TF-IDF	0.7815 (78.15%)	0.7831 (78.31%)	0.7860 (78.60%)	0.7846 (78.46%)	0.8676 (86.76%)
4. Decision Tree + TF-IDF	0.6681 (66.81%)	0.6482	0.7529 (75.29%)	0.6966 (69.66%)	0.7124 (71.24%)

การเปรียบเทียบประสิทธิภาพโมเดลจำแนกข้อความ (Overall Model Comparison on Test Set)



รูปที่ 5: แผนภูมิแท่งเปรียบเทียบค่า Metrics 5 ด้านของทั้ง 4 โมเดลบนชุดข้อมูลทดสอบ (Test Set)

การวิเคราะห์เมทริกซ์ความสับสน (Confusion Matrices Analysis):



รูปที่ 6: เมทริกซ์ความสับสน (Confusion Matrices) ทั้ง 4 โมเดลบน Test Set (จำนวนตัวอย่างรวม 4,902 ตัวอย่าง)

จุดเด่นด้าน Recall ของ BiLSTM:
BiLSTM ทำนายผู้มีภาวะซึมเศร้าถูกต้องถึง **2,130 เคส** จาก **2,481 เคส** (False Negative ต่ำเพียง 351 เคส) ส่งผลให้ Recall สูงถึง **85.85%** มีความปลอดภัยสูงสุดสำหรับเครื่องมือคัดกรองเบื้องต้น (Screening Tool)

ความแม่นยำสูง (Precision) ของ LR + TF-IDF:
Logistic Regression ร่วมกับ TF-IDF มีอัตราการเตือนผิดพลาด (False Positive) ต่ำสุด โดยทายผิดเป็นซึมเศร้าเพียง 540 เคส ส่งผลให้ค่า **Precision สูงสุดที่ 78.31%** และมีความสมดุลสูงสุดระหว่าง Precision และ Recall

4.1 การวิเคราะห์เปรียบเทียบเชิงลึก (In-Depth Technical Insights)

- ทำไม **BiLSTM** ถึงให้ผลลัพธ์โดยรวมดีที่สุด (**Accuracy 78.40%, F1 80.09%, AUC 87.15%**): โมเดล Deep Sequential สามารถเข้าใจ ลำดับของคำ (Word Order) และ บริบทความหมาย (Contextual Semantics) ผ่าน Word2Vec Dense Vector ซึ่งข้อความแสดงภาวะซึมเศร้ามักมีการใช้คำปฏิเสธซ้อน (เช่น "ไม่อยากมีชีวิตอยู่", "รู้สึกว่างเปล่า") ซึ่งโมเดลแบบ Bag of Words ไม่สามารถจับลำดับคำได้สมบูรณ์เท่า
- การเปรียบเทียบ **BoW vs TF-IDF** บน **Logistic Regression**: TF-IDF ช่วยลดน้ำหนักของคำทั่วไป (Stop Words) และเน้นคำเฉพาะอาการทางจิตเวช ส่งผลให้ Precision เพิ่มขึ้นจาก 75.74% เป็น **78.31%**
- สาเหตุที่ **Decision Tree** มีประสิทธิภาพต่ำกว่าโมเดลอื่น (**Accuracy 66.81%**): ข้อมูลข้อความที่ผ่านการแปลงเวกเตอร์มีมิติสูงมาก (> 47,000 มิติ) และเบาบาง (Extremely Sparse) ทำให้ Decision Tree ซึ่งแบ่งข้อมูลตามแกนตั้งฉาก (Axis-aligned Splits) ครึ่งละ 1 ฟิเจอร์ เกิดความยากลำบากในการสร้าง Decision Boundary ที่มีประสิทธิภาพ

4.2 บทสรุปและข้อเสนอแนะสำหรับการพัฒนาต่อยอด (Conclusion & Future Directions)

โครงการนี้ประสบความสำเร็จในการออกแบบและเปรียบเทียบระบบจำแนกข้อความภาษาไทยเพื่อคัดกรองภาวะซึมเศร้า โดยพบว่า **BiLSTM + Pre-trained Word2Vec** เป็นโมเดลที่มีประสิทธิภาพสูงสุด และ **Logistic Regression + TF-IDF** เป็นโมเดลทางเลือกที่ประมวลผลได้รวดเร็วและมีความแม่นยำสูง

แนวทางการพัฒนาต่อยอดในอนาคต (Future Directions):

- Pre-trained Transformer Models:** ทดลองประยุกต์ใช้โมเดลภาษาไทยระดับ State-of-the-Art เช่น WangchanBERTa หรือ mBERT เพื่อยกระดับความเข้าใจบริบทประโยคเชิงลึก
- Ensemble Modeling:** ผสานจุดเด่นของ BiLSTM (High Recall) และ Logistic Regression TF-IDF (High Precision) ด้วยวิธี Soft Voting เพื่อเพิ่มประสิทธิภาพรวม
- Multi-Class Severity Classification:** ขยายผลจากการจำแนก 2 คลาส (Binary) ไปสู่การจำแนกระดับความรุนแรงของภาวะซึมเศร้า (Minimal, Mild, Moderate, Severe)